Ouvidoria Inteligente — Triagem Semântica de Manifestações Cidadãs

Aluno: Ricardo Silva Flores
Disciplina: Processamento de Linguagem Natural / Engenharia de IA

1. Objetivo e cenário

A Ouvidoria Geral de um município recebe manifestações textuais sobre infraestrutura, saúde, segurança, educação e meio ambiente. A classificação baseada somente em palavras-chave dificulta localizar relatos equivalentes escritos com vocabulários diferentes, identificar duplicatas e processar denúncias extensas. Este trabalho desenvolveu um protótipo de triagem semântica para apoiar a recuperação de manifestações relacionadas.

A base fornecida possui 40 textos anônimos. A solução foi organizada em quatro entregas: comparação de representações, detecção de duplicatas, chunking dos textos longos e aplicação interativa em Streamlit.

2. Representações vetoriais

Foram comparadas três abordagens. Bag-of-Words (BoW) registra a frequência dos termos e funciona bem para coincidências literais, mas não entende sinônimos. TF-IDF também é esparso, porém reduz o peso de palavras muito frequentes e valoriza termos mais específicos.
Por fim, embeddings densos foram gerados pelo modelo multilíngue `paraphrase-multilingualMiniLM-L12-v2`, permitindo calcular proximidade semântica com similaridade de cosseno.

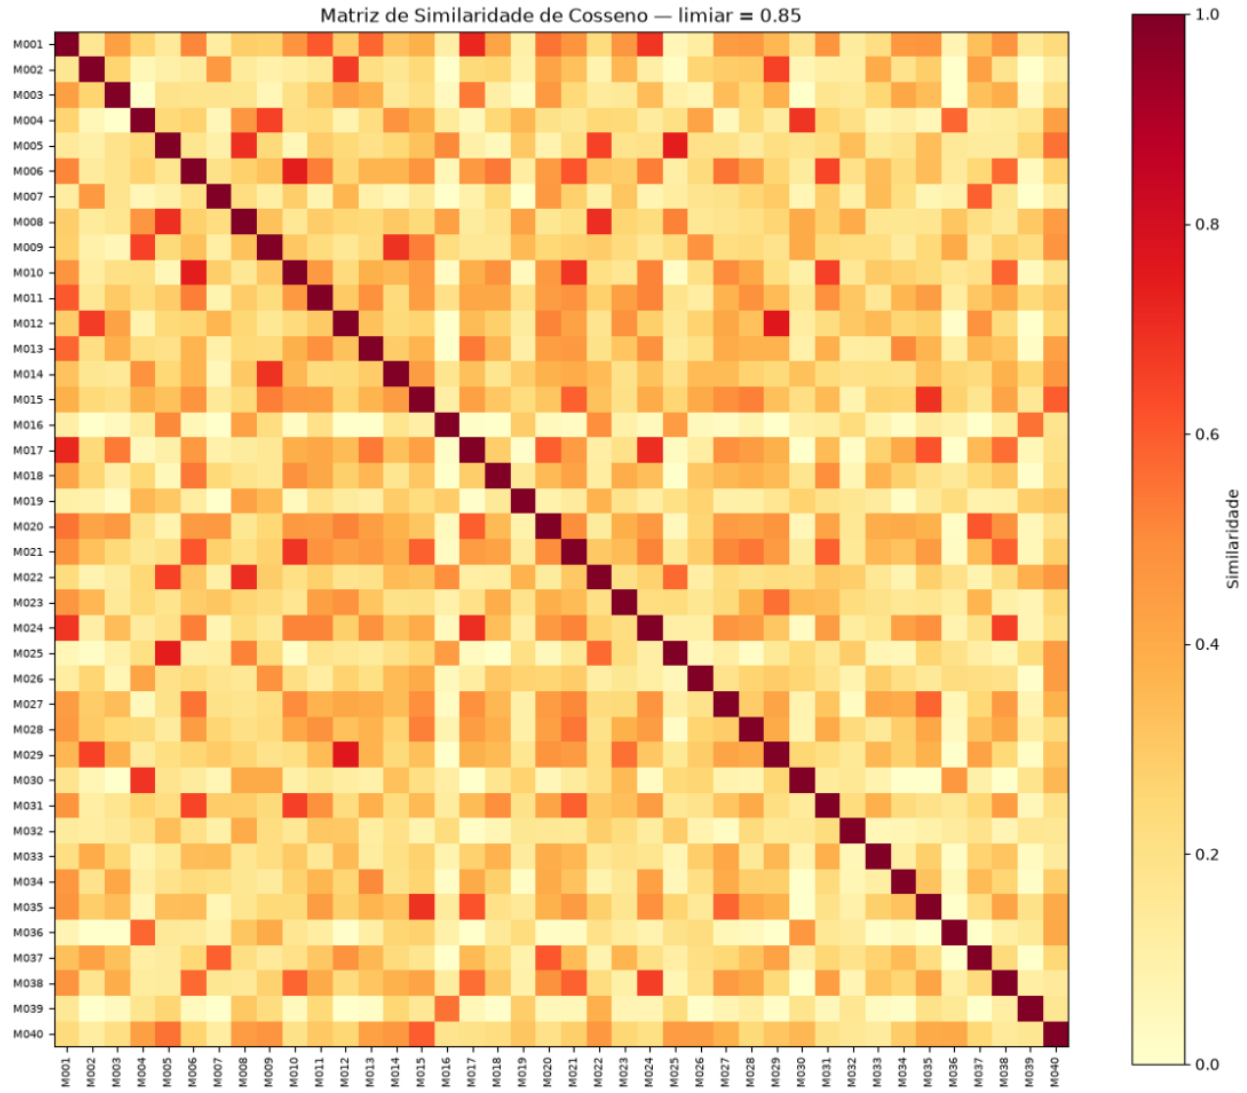
Os pares obrigatórios foram M003 × M017, sobre buracos e asfalto esburacado; M008 × M022, sobre indisponibilidade de médico/atendimento em posto de saúde; e M008 × M031, que contrasta saúde com iluminação pública. A expectativa é que os dois primeiros pares sejam mais bem reconhecidos pelos embeddings do que pelas representações baseadas exclusivamente em termos compartilhados, enquanto M008 × M031 permaneça distante.

	Par	BoW	TF-IDF	Embeddings
0	M003 × M017	0.1886	0.0520	0.5373
1	M008 × M022	0.2619	0.0710	0.7005
2	M008 × M031	0.2294	0.0646	0.2827

3. Duplicatas e limiar

A detecção de duplicatas foi implementada pela função `detectar_duplicatas(textos, limiar=0.85)`. A função gera os embeddings, calcula uma matriz de similaridade de cosseno e devolve os pares cujo score seja maior ou igual ao limiar. O valor 0,85 foi escolhido inicialmente para priorizar precisão: manifestações só são tratadas como possíveis duplicatas quando existe elevada proximidade semântica.

Pares como M003 × M017 e M008 × M022 devem ser inspecionados como candidatos esperados. Caso um deles fique abaixo do limiar, ele representa possível falso negativo, indicando que a redação, o tamanho dos textos ou um limiar muito rígido influenciaram o resultado. Em sentido oposto, relatos diferentes da mesma categoria que ultrapassem 0,85 devem ser discutidos como falsos positivos. A matriz de calor permite visualizar blocos de manifestações próximas.



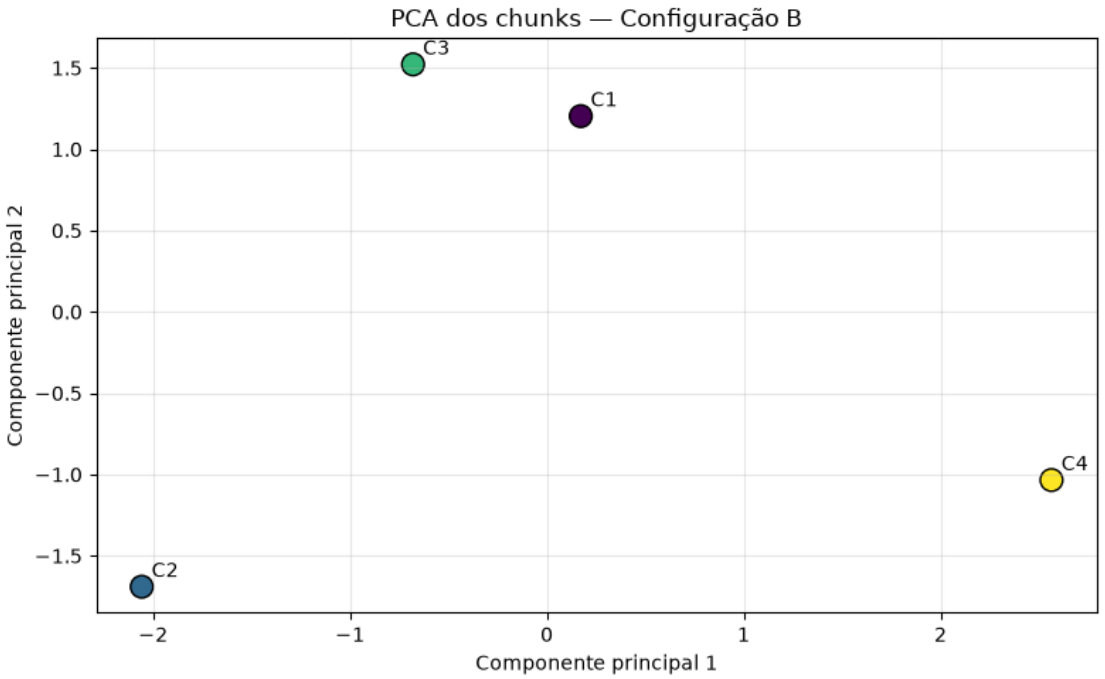
4. Chunking e app

As cinco manifestações mais longas foram selecionadas automaticamente. Foram comparadas duas configurações usando `RecursiveCharacterTextSplitter`: configuração A com `chunk_size=300` e `chunk_overlap=40`; e configuração B com `chunk_size=420` e `chunk_overlap=100`. O overlap preserva parte do contexto entre blocos consecutivos. A configuração A produz fragmentos menores, úteis para buscas específicas, enquanto a configuração B preserva melhor o encadeamento de denúncias longas, solicitações e justificativas.

O aplicativo `app_ouvidoria.py` possui quatro abas. A aba Busca Semântica retorna as manifestações mais similares com indicação visual por score. A Base Completa exibe os 40 registros e gera uma matriz de similaridade. O Espaço Vetorial usa PCA ou t-SNE para mostrar proximidade entre textos e suas categorias oficiais. A aba Chunking permite colar uma manifestação, ajustar tamanho e overlap, ver os blocos e comparar a coesão entre chunks consecutivos.

	id	categoria_oficial	tamanho_caracteres
39	M040	educação	958
34	M035	segurança	935
24	M025	saúde	922
14	M015	segurança	786
4	M005	saúde	691

	Manifestação	Configuração	chunk_size	chunk_overlap	Quantidade de chunks	Tamanho dos chunks
0	M040	Configuração A	300	40	4	[282, 243, 230, 203]
1	M040	Configuração B	420	100	4	[282, 243, 230, 203]
2	M035	Configuração A	300	40	4	[127, 229, 298, 281]
3	M035	Configuração B	420	100	3	[356, 298, 380]
4	M025	Configuração A	300	40	4	[266, 218, 162, 276]
5	M025	Configuração B	420	100	3	[266, 380, 276]
6	M015	Configuração A	300	40	4	[116, 222, 259, 189]
7	M015	Configuração B	420	100	3	[338, 259, 189]
8	M005	Configuração A	300	40	3	[267, 272, 152]
9	M005	Configuração B	420	100	3	[267, 272, 238]



5. Limitações e aprendizados

Embeddings melhoram a recuperação de sinônimos e formulações distintas, mas os scores não constituem uma verdade absoluta: o limiar de duplicata precisa ser calibrado e confirmado por revisão humana. A visualização PCA/t-SNE reduz um espaço de muitas dimensões para duas dimensões, sendo útil para exploração, mas não para decisões isoladas. Também há sobreposição temática: iluminação, por exemplo, pode envolver infraestrutura e segurança ao mesmo tempo.

O trabalho demonstrou que a combinação de embeddings, similaridade de cosseno, detecção por limiar e chunking pode tornar a triagem inicial mais rápida e consistente. A decisão final sobre encaminhamento de uma manifestação, entretanto, deve continuar sob supervisão humana.